ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas · Carrera de Ciencia de Datos e Inteligencia Artificial

INFORME DE PRÁCTICA N.º 1

Consolidación de reportes de ventas (CSV, JSON y Excel)

Tópico 1 del PEA · Asignatura IDSD422 — Estadística y Programación para Ciencia de Datos I

Estudiante(s)	Villacís Vega, Alejandro Xavier — usuario de GitHub: altas123linux
Docente	Ing. Christian Suárez, M.Sc.
Período académico	2026-B
Fecha de entrega	19/10/2026
Repositorio (fork)	https://github.com/altas123linux/IDSD422-lab1-lectura-datos.git

1. Introducción

RetailAndina S.A. recibe cada semana su reporte de ventas por sucursal desde tres subsistemas contables independientes, y cada uno lo entrega en un formato distinto: CSV, JSON y XLSX. El equipo BI debe confirmar que los tres archivos contienen la misma información y describir su estructura antes de calcular los indicadores para la gerencia (Suárez, 2026).

Los datos son cinco sucursales de las regiones Sierra y Costa, con cuatro variables entre ellas sucursal, región, ventas y clientes. Leí los archivos en Python y en R, comparé dimensiones y tipos de dato y calculé la venta promedio, el ticket promedio por cliente y las sucursales y regiones de mayor y menor desempeño. La práctica corresponde a llevar fuentes heterogéneas a una tabla de filas y columnas.

2. Objetivos

Objetivo general. Analizar un mismo reporte de ventas regional disponible en formatos CSV, JSON y Excel, verificando que su lectura en Python y en R muestren consistencia en los datos proporcionados.

Objetivos específicos.

1. Leer los archivos ventas.csv, ventas.json y ventas.xlsx en Python y en R.
2. Verificar y comparar las dimensiones y los tipos de dato de cada variable en ambos entornos.
3. Calcular la venta promedio, el ticket promedio, las sucursales de mayor y menor venta y la región líder.
4. Reportar las diferencias observadas entre formatos.

3. Desarrollo de la práctica

Trabajé en Google Colab para y en Posit Cloud para R con los archivos del fork del repositorio.

3.1 Lectura de los tres formatos en Python - Google Colab

Empareje Google Drive en Colab y leí cada formato con la función de pandas que le corresponde como read_csv(), read_excel() para la hoja ventas del XLSX y, para el JSON, json.load() seguido de json_normalize(), porque el JSON es texto jerárquico y hay que aplanarlo a tabla. En los tres casos imprimí head(), shape y dtypes. Esto también lo realice dentro del IDE Visual Studio Code para mi repositorio de git hub. Por otro lado, Los tres formatos produjeron el mismo DataFrame 5 , 4, con sucursal y región como object y ventas y clientes como int64. Tuve errores de ruta al cambiar de entorno: en Colab abrí los archivos por su nombre (ventas.csv) y luego usé la ruta relativa del repositorio (data/ventas.csv), igual que en Posit Cloud.

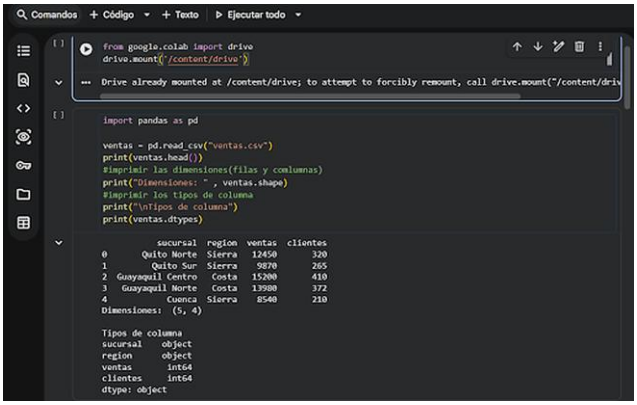


Figura 1. Lectura del CSV en Python con pd.read_csv(): shape (5, 4) y tipos de columna (object e int64).



Figura 2. Lectura del JSON en Python con json.load() y pd.json_normalize(): mismo resultado, (5, 4).

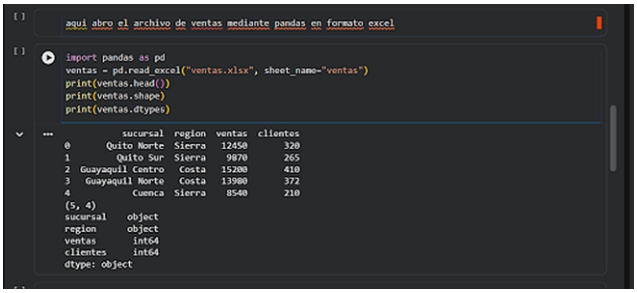


Figura 3. Lectura de la hoja ventas del Excel con pd.read_excel(): mismo resultado, (5, 4).

3.2 Cálculo de indicadores comerciales en Python

Sobre el CSV creé la variable derivada ticket = ventas / clientes, que es la venta media por cliente de cada sucursal. El ticket promedio lo calculé como suma de ventas / suma de clientes y no como el promedio de los tickets, para que las sucursales con más clientes pesen más.

Sucursal	Región	Ventas	Clientes	Ticket
Quito Norte	Sierra	12,450	320	38.91
Quito Sur	Sierra	9,870	265	37.25
Guayaquil Centro	Costa	15,200	410	37.07
Guayaquil Norte	Costa	13,980	372	37.58
Cuenca	Sierra	8,540	210	40.67

Tabla 1. Ventas, clientes y ticket por sucursal (salida de la Figura 4).

Esta tabla muestra la venta promedio por sucursal fue $12,008.00 y el ticket promedio $38.07. Guayaquil Centro tuvo la mayor venta $15,200 y Cuenca la menor $8,540. Por región, Sierra sumó $30,860 y Costa $29,180. Cuenca vende menos, pero tiene el ticket más alto $40.67: atiende pocos clientes 210 que gastan más cada uno. Guayaquil Centro, al contrario, tiene el ticket más bajo $37.07 pero vende más porque atiende más clientes 410.

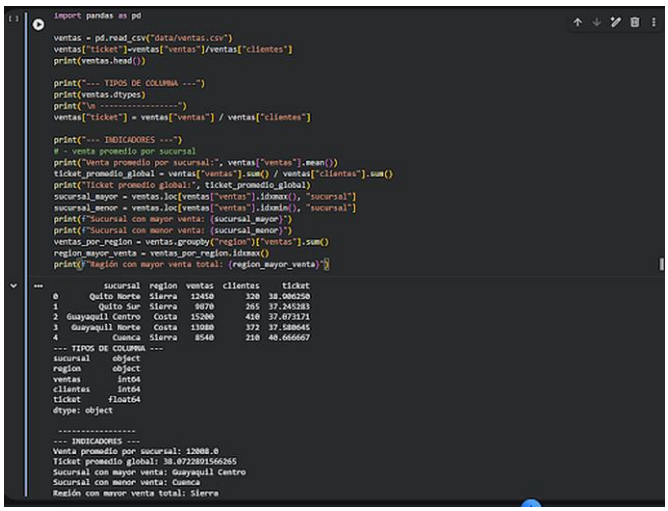


Figura 4. Código y salida en Python: ticket por sucursal, tipos de columna e indicadores agregados.

3.3 Lectura de los formatos en R - Posit Cloud

En R usé readr::read_csv() para el CSV, jsonlite::fromJSON() para el JSON y readxl para el Excel, y verifiqué la estructura con dim() y str(). El paquete jsonlite no estaba instalado en el entorno, así que lo instalé con install.packages(jsonlite). Además, fromJSON() hizo el aplanamiento y devolvió un data frame de 5 × 4. Esto también lo realice dentro del IDE Visual Studio Code para mi repositorio de git hub. Las dimensiones coinciden (5 × 4) y los valores son idénticos. La única discrepancia es: pandas lee ventas y clientes como enteros int64, mientras que readr los lee como decimales dbl, sucursal y region son texto en ambos object y chr. No afecta los cálculos de esta práctica, pero importaría si se compararan los tipos de forma estricta.

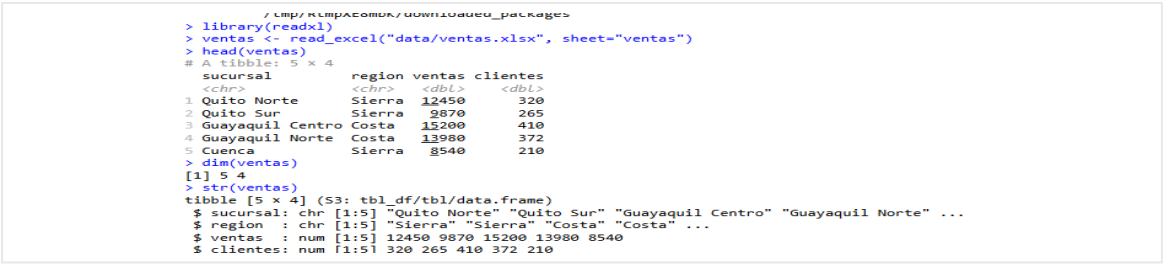


Figura 4. Lectura de ventas.xlsx en R con readxl:: read_excel() dimensión 5 × 4.

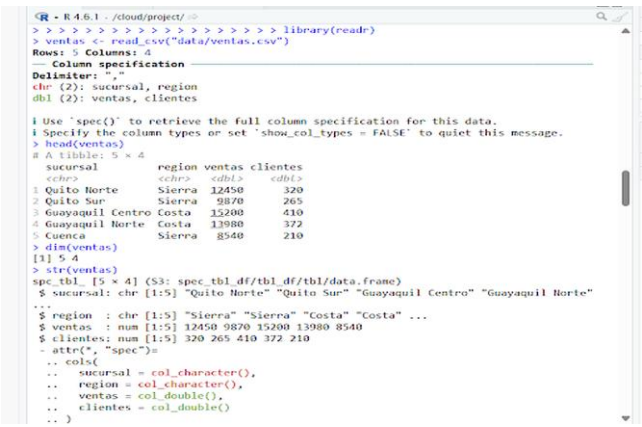


Figura 5. Lectura de ventas.csv en R con readr::read_csv(): dimensión 5 × 4 y especificación de columnas.

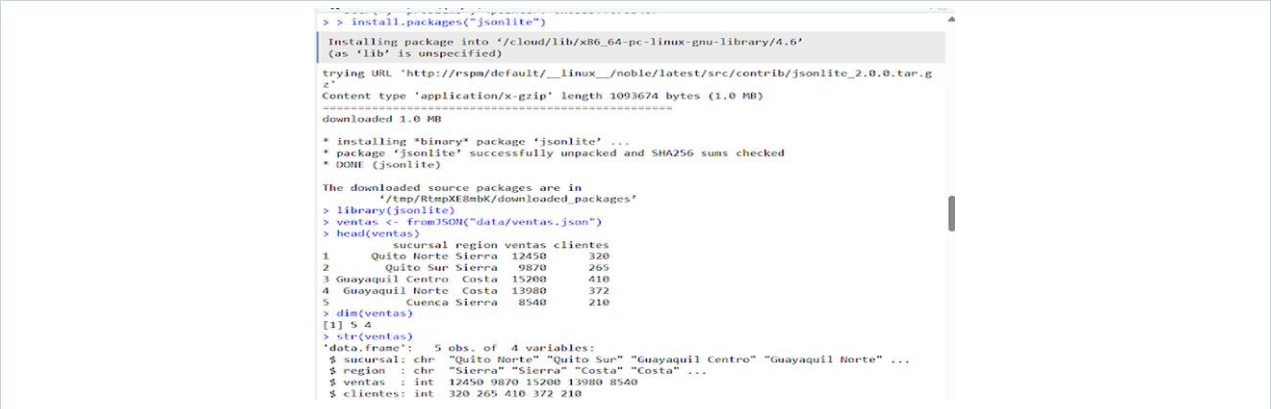


Figura 6. Instalación de jsonlite y lectura de ventas.json en R con fromJSON(): dimensión 5 × 4.

3.4 Indicadores en R y verificación cruzada

Repetí el cálculo en R con el mismo criterio que en Python: ticket por sucursal, promedio simple de ventas y ticket global ponderado. El código comentado está en el Anexo A y también se ve completo en la Figura 7.

Indicador	Python	R
Venta promedio por sucursal	12008.0	12008
Ticket promedio global	38.0722891566265	38.07229
Sucursal con mayor venta	Guayaquil Centro	Guayaquil Centro
Sucursal con menor venta	Cuenca	Cuenca
Región con mayor venta total	Sierra	Sierra

Tabla 2. Verificación cruzada de los indicadores entre Python y R.

En esta tabla los cinco indicadores coinciden. La diferencia en el ticket (38.0722891566265 frente a 38.07229) es solo de impresión: cat() en R muestra siete cifras significativas y pandas imprime la precisión completa.

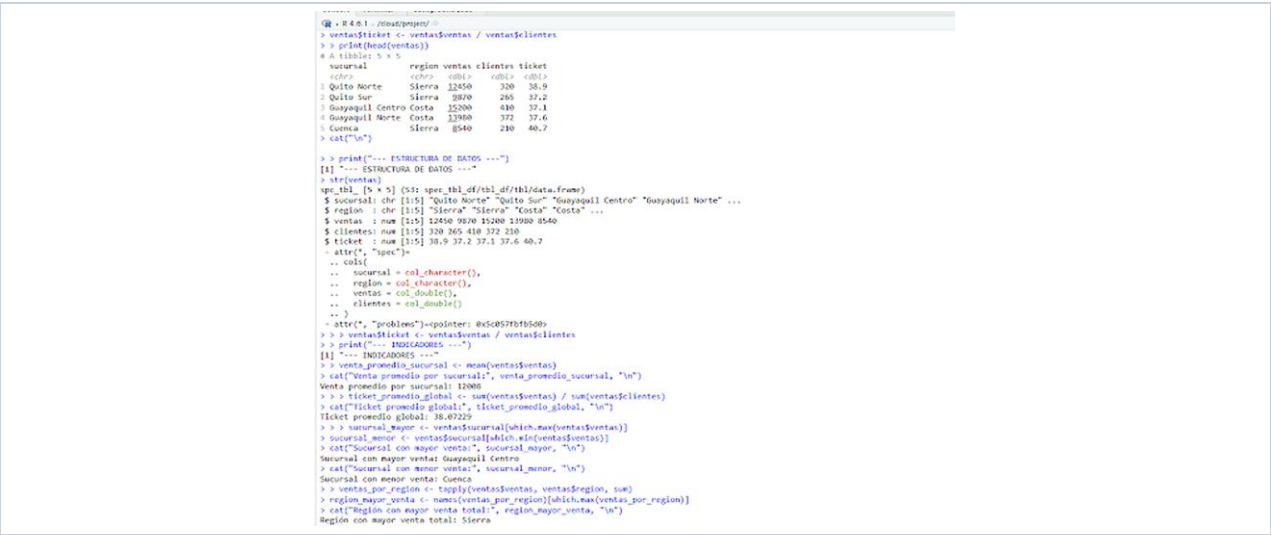


Figura 7. Cálculo de la variable derivada y los indicadores en R: mismos resultados que en Python.

4. ¿Qué aprendí con esta práctica?

Durante el desarrollo de la práctica en los lenguajes de Python y R aprendí que cada formato necesita su propia función y que hay que verificar dimensiones y tipos antes de calcular. Entendí por qué un JSON hay

que aplanarlo antes de analizarlo ya que es texto jerárquico, y json_normalize() en Python o fromJSON() en R lo convierten en una tabla de filas y columnas. También reafirmé la diferencia entre el ticket promedio simple por sucursal y el ticket promedio global, que debe ponderarse por el total de clientes.

Lo más difícil fueron los errores de ruta al pasar de Google Colab a Posit Cloud y la instalación del lenguaje de R en visual studio code ya que no lo tenía instalado a diferencia de Python y también en cierta parte de jsonlite. Los resolví usando rutas relativas desde la raíz del proyecto (data/ventas.csv) y trabajando con el repositorio en Git, para que el proyecto sea reproducible. La próxima vez usaré rutas relativas desde el inicio y comprobaré la equivalencia entre formatos con una comparación explícita en código, en lugar de revisar las tablas a simple vista.

5. Conclusiones

1. En Python, los tres formatos produjeron el mismo DataFrame de 5 filas × 4 columnas, con los mismos tipos object, object, int64, int64; En R, el CSV y el JSON confirmaron la misma dimensión 5 × 4.
2. La venta promedio por sucursal fue $12,008.00. Guayaquil Centro tuvo la mayor venta $15,200 y Cuenca la menor $8,540. Sierra concentró la mayor venta acumulada $30,860 frente a $29,180 de Costa. Python y R dieron los mismos resultados.
3. El ticket promedio global ponderado fue $38.07 por cliente. Cuenca, aunque tiene la menor facturación, registró el ticket más alto $40.67, mientras que Guayaquil Centro vende más por volumen de clientes 410 y no por ticket $37.07.

5. Bibliografía y declaración de uso de IA

pandas development team. (2026). *pandas.read_csv, pandas.read_excel y pandas.json_normalize*. https://pandas.pydata.org/docs/reference/api/pandas.read_csv.html

Suárez, C. (2026). *IDSD422-lab1-lectura-datos: archivos ventas.csv, ventas.json y ventas.xls*. Escuela Politécnica Nacional.

Wickham, H., Çetinkaya-Rundel, M. y Grolemund, G. (2023). *R for Data Science* (2.ª ed.). O'Reilly Media. https://r4ds.hadley.nz/

Declaración de uso de IA: Claude como asistente de apoyo para la maquetación, presentación de código en un solo bloque para los anexos y la redacción del informe para que me proporcionara fuentes bibliográficas. La ejecución del código en Google Colab y Posit Cloud, las capturas y la verificación de los resultados son propias.

Anexo A. Código clave comentado de los indicadores

Python (Google Colab), sobre el DataFrame leído del CSV:

```
ventas["ticket"] = ventas["ventas"] / ventas["clientes"]   # ticket por sucursal
ticket_glob = ventas["ventas"].sum() / ventas["clientes"].sum()   # global ponderado
mayor = ventas.loc[ventas["ventas"].idxmax(), "sucursal"]  # mayor venta (idxmin: menor)
region_mayor = ventas.groupby("region")["ventas"].sum().idxmax()  # región líder
```

R (Posit Cloud), sobre el data frame leído del CSV:

```
ventas$ticket <- ventas$ventas / ventas$clientes
ticket_promedio_global <- sum(ventas$ventas) / sum(ventas$clientes)  # ponderado
sucursal_mayor <- ventas$sucursal[which.max(ventas$ventas)]  # which.min: menor
ventas_por_region <- tapply(ventas$ventas, ventas$region, sum)
region_mayor_venta <- names(ventas_por_region)[which.max(ventas_por_region)]
```